




Distribuciones y Muestreo

Aprende a trabajar con muestras, medir incertidumbre y aplicar estos conceptos fundamentales en Data Science.

Población vs Muestra



Conceptos fundamentales

Población: Todos los datos posibles que queremos estudiar. Es el conjunto completo de elementos de interés.

Muestra: Subconjunto representativo de la población. Es lo que realmente podemos analizar en la práctica.

En la práctica

- No analizamos toda la población (impráctico o imposible)
- Usamos muestras para estimar características poblacionales
- La clave está en seleccionar buenas muestras

¿Qué es el muestreo?

El muestreo es la **selección de datos desde una población** y constituye la base de todo análisis estadístico. Una buena muestra es representativa y permite hacer inferencias válidas.



Aleatorio simple

Cada elemento tiene igual probabilidad de ser seleccionado



Estratificado

Divide la población en grupos y muestrea de cada uno



Sistemático

Selecciona elementos en intervalos regulares


Importancia del muestreo

Calidad vs Cantidad

Más datos $\neq$ mejores resultados. Lo realmente importante es la **representatividad** de la muestra, no su tamaño absoluto.

Una muestra sesgada, por grande que sea, llevará a conclusiones erróneas. Por eso, la técnica de selección es más crucial que el número de observaciones.

📄 👉 **Principio clave:** Una mala muestra produce conclusiones erróneas, sin importar cuán sofisticado sea el análisis.



Sesgo (Bias)

¿Qué es el sesgo?

Un **error sistemático** en los datos que distorsiona los resultados. No es aleatorio, sino que empuja consistentemente en una dirección.

Sesgo de muestra

La muestra no representa adecuadamente a la población. Por ejemplo, encuestar solo en zonas urbanas para representar todo un país.

Sesgo de autoselección

Los participantes eligen participar, creando una muestra no aleatoria. Ejemplo: reviews en internet no son representativos.

Distribución muestral


¿Qué es?

La **distribución de un estadístico** (como la media) calculado en muchas muestras diferentes de la misma población.

Idea clave

Esta distribución **tiende a ser normal** (forma de campana), incluso si los datos originales no lo son.

Este comportamiento es la base del análisis estadístico y permite hacer inferencias sobre poblaciones.



Variabilidad y error

¿Por qué hay incertidumbre?

Cada muestra es diferente y, por lo tanto, **los resultados cambian** de una muestra a otra. Esta variabilidad es natural y debe ser cuantificada.



Error estándar

Medida de variabilidad del estadístico



Variabilidad muestral

Cuánto varían los resultados entre muestras



Bootstrap


Técnica moderna de remuestreo

El **bootstrap** es una técnica computacional poderosa que remuestrea con reposición para simular muchas muestras a partir de una sola.


¿Para qué sirve?

- Estimar la variabilidad de estadísticos
- Construir intervalos de confianza
- Realizar pruebas de hipótesis

Muy utilizada en Data Science por su flexibilidad y poder computacional.



Bootstrap resampling



Intervalos de confianza

¿Qué son?

Un **rango donde probablemente esté el valor real** de un parámetro poblacional. No es una afirmación exacta, sino una estimación con incertidumbre cuantificada.



Mayor confianza → intervalo más amplio

Quieres 99% de confianza? Tu intervalo será más ancho que con 95%.



Menos datos → más incertidumbre

Con pocas observaciones, los intervalos son más amplios y menos precisos.



Uso práctico: Medir precisión de estimaciones y tomar decisiones informadas con incertidumbre cuantificada.